

Indexation Web

Janvier 2026

Lara Perinetti - Team Lead Search



Ask Le Chat anything



∞ Research



Think



Tools



Parlez-moi de vous

- Combien vous êtes dans chaque groupe ?
- Quels langages de programmation vous connaissez ?
- A quel point vous êtes familiers avec les notions du web ?
 - HTML, css, javascript ?
 - Flux rss ?
 - robots.txt ?
- Avez-vous déjà étudié le NLP ? IR ?

Cours Indexation Web

- 6h CM en commun
- 3 * 3h TP
 - Crawler
 - Index
 - Moteur de recherche final

Cours Indexation Web

Rendus des TPs

- Les TPs seront à rendre dans un **repository git public**
- A chaque fin de TP, il faudra push votre avancement
- Vous aurez une semaine de plus si vous n'avez pas fini pour me (re) envoyer le code amélioré et m'envoyer la version définitive
- TP Crawler - 13/01
- TP Index - 13/01
- TP Moteur - 14/01
- Tous les TPs sont à envoyer au plus tard le **21/01**

Introduction

Partie 1: Constitution d'un index web

1. Architecture d'un moteur de recherche
2. Crawler le web
3. Document Processing

Partie 2: Traitement de la requête et ordonnancement des résultats

1. Index
2. Compréhension de la requête
3. Ordonnancement des résultats et évaluation
4. Retrieval Augmented Generation (RAG)

Qu'est-ce qu'un moteur de recherche?

Differents types

- **Web Search:** Google, Qwant, DuckDuckGo, Ecosia etc.
 - Differents formats: HTML, pdf, docx etc.
 - Champs les plus communs: title, content, page rank
- **Shopping Search:** Amazon, Cdiscount, La Redoute etc.
 - Leurs propres structures de données, appliquer des filtres
 - Champs les plus communs: nom du produit, prix, image
- **Desktop Search:** sur les ordinateurs personnels
 - fichiers, emails, pages webs dans l'historiques des recherches
 - Séparer les sources de données
- **IA Search:**
 - Le contenu sémantique est bien plus important pour que le modèle génère une réponse avec
 - On cherche à avoir des sources fiables et de qualité

Qu'est-ce qu'un moteur de recherche?

SERP
Search
Engine
Results
Pages

Paid
Results

Organic
Results

Search
Engine
Features

Qwant

canal +

×

🔍

🔍 All

📰 News

🖼️ Images

📺 Videos

🛒 Shopping

📍 Maps

France ▾ Any freshness ▾

+

boutique.canalplus.com › Série_Limitée › Canal_Plus

Série Limitée - CANAL+, DISNEY+ & PARAMOUNT+

Ad Série Limitée **CANAL+** & DISNEY+ & PARAMOUNT+pour 25,99€/mois pdt 12 mois puis 35,99€/mois. A Noël, partagez vos films préférés avec la Série Limitée **CANAL+**,...
CANAL+ Série · Offre CANAL+ -26 ans · CANAL+ Ciné Série · CANAL+ Sport

Ads by Microsoft ⓘ

+

canalplus.com

myCANAL : tv, sports, séries, films en streaming en direct live ou...

Regarder les meilleurs programmes, films, séries, sports en streaming direct ou en replay.
Le programme TV de toutes les chaines est gratuit et sans pub.

W

fr.wikipedia.org › wiki › MyCanal

MyCanal

My**Canal**, stylisé en my**CANAL**, est un service français de distribution de contenu par Internet du groupe **Canal+** lancé en décembre 2013. Il permet d'accéder aux programme...

Canal+

Chaîne de télévision française

Canal+ est une chaîne de télévision généraliste nationale française privée à péage, axée sur le cinéma et le sport. Lancée le 4 novembre 1984 par Havas, elle fut la toute première chaîne privée à péage en France. Elle appartient à la Société...

[Read more on Wikipedia](#)

Pays : France

Site Web : www.canalplus.com

Propriétaire : Vivendi

Wikipedia.org · [How to contribute?](#)

Share your feedback

8

SERP
Search
Engine
Results
Pages

Paid Results

Organic Results

Search Engine Features

The image is a screenshot of a Qwant search engine interface. At the top left is the Qwant logo. A search bar contains the text 'canal +'. To the right of the search bar are icons for a close button (X) and a search button (magnifying glass). In the top right corner, there are icons for a grid of apps and a settings gear.

Below the search bar is a navigation bar with the following items: 'All' (with a magnifying glass icon), 'News' (with a newspaper icon), 'Images' (with a picture icon), 'Videos' (with a play button icon), 'Shopping' (with a shopping cart icon), and 'Maps' (with a location pin icon). The 'All' item is currently selected.

The main content area displays search results. At the top, there are filters: 'France' with a dropdown arrow and 'Any freshness' with a dropdown arrow. Below the filters, the first result is highlighted with a red border. It is an advertisement from 'boutique.canalplus.com' for 'Série Limitée - CANAL+, DISNEY+ & PARAMOUNT+'. The ad text describes a 12-month offer for 25,99€/month, plus 35,99€/month after Christmas, and lists various Canal+ content. It is marked as 'Ads by Microsoft'.

The second result is highlighted with a blue border. It is from 'canalplus.com' and is titled 'myCANAL : tv, sports, séries, films en streaming en direct live ou...'. The description mentions that it allows watching the best programs, films, series, and sports in streaming direct or on replay, and that the TV program is free and without ads.

The third result is highlighted with a light blue border. It is from 'fr.wikipedia.org' and is titled 'MyCanal'. The description states that MyCanal is a French content distribution service launched in December 2013, allowing access to Canal+ programs.

On the right side of the page, there is a detailed information panel for 'Canal+' highlighted with a yellow border. It includes the title 'Canal+', the subtitle 'Chaîne de télévision française', a paragraph describing it as a private pay-TV channel launched in 1984, a link to 'Read more on Wikipedia', and key information: 'Pays : France', 'Site Web : www.canalplus.com', and 'Propriétaire : Vivendi'. At the bottom of this panel, there is a link to 'Wikipedia.org • How to contribute?' and a 'Share your feedback' button.

Information Retrieval

- *“Information retrieval is a field concerned with the structure, analysis, organization, storage, searching, and retrieval of information.”* (Salton, 1968)
- Définition moderne : La recherche d'information est la science qui permet d'identifier et d'extraire des documents pertinents à partir d'une vaste collection de données non structurées, en réponse à un besoin d'information spécifique.
- Exclut : Systèmes de recommandation (Netflix, Spotify)
- Défis fondamentaux :
 - Subjectivité de la pertinence
 - Inadéquation requête-besoin

Information Retrieval

Qu'est-ce qu'un document web?

- On va se concentrer sur les pages HTML
Balises les plus courantes:

Exemple

- Structure et nom des balises :
 - Les balises suivent des normes réglementées (W3C).
 - Elles peuvent contenir : Texte / Images / Vidéos / Script / Liens
 - Métadonnées :
 - Les métadonnées (dans la balise <head>) sont des informations sur le document et non sur son contenu.
 - Exemple : type de document, description, mots-clés pour les moteurs de recherche.

```
<head>
  <title>Mon site web</title>
  <link rel="stylesheet" href="style.css">
</head>
<body>
  <h1>Titre principal</h1>
  <div>
    <p>Exemple de paragraphe</p>
  </div>
</body>
```

Information Retrieval

Qu'est-ce qu'une requête web ?

- Spécificités d'une requête web: souvent courte (un ou deux termes) et ambiguë
- On définit **3 intentions principales** pour une requête web
 - Navigationnelle
 - Transactionnelle
 - Informationnelle
- On peut définir **plusieurs topics** pour une requête web
 - Exemple:
requête: Jaguar
topics: animal / voiture

Information Retrieval

What is a web query ?

Exemples de requetes d'utilisateurs Qwant en décembre 2022

youtube

[https://
www.ensai.fr/](https://www.ensai.fr/)

cabinet comptable
cfac cenon

Nice Marseille
train

maladroit en
anglais

le monde

Voiture occasion

Reine
d'angleterre

météo paris

Atelier solidaire à
Dignes les bains

Jean luc godard

Argentine france

Avatar 2

Ikea

Les classer par intention (informationnelle, transactionnelle, navigationnelle)

Information Retrieval

What is a web query ?

Exemples de requetes d'utilisateurs Qwant en décembre 2022

youtube

maladroit en
anglais

Reine
d'angleterre

Argentine france

https://
www.ensai.fr/

cabinet comptable
cfac cenon

météo paris

Avatar 2

Nice Marseille
train

Voiture occasion

le monde

Atelier solidaire à
Dignes les bains

Jean luc godard

Ikea

Les classer par intention (informationnelle, transactionnelle, navigationnelle)

Information Retrieval

What is a web query ?

Exemples de requetes d'utilisateurs Qwant en décembre 2022

youtube

maladroit en
anglais

Reine
d'angleterre

Argentine france

météo paris

[https://
www.ensai.fr/](https://www.ensai.fr/)

cabinet comptable
cfac cenon

le monde

Atelier solidaire à
Dignes les bains

Avatar 2

Nice Marseille
train

Voiture occasion

Jean luc godard

Ikea

Les classer par topics (pas plus de deux topics par requête)

Information Retrieval

What is a web query ?

Exemples de requetes d'utilisateurs Qwant en décembre 2022

youtube

maladroit en
anglais

Reine
d'angleterre

Argentine france

[https://
www.ensai.fr/](https://www.ensai.fr/)

cabinet comptable
cfac cenon

météo paris

Avatar 2

Nice Marseille
train

le monde

Atelier solidaire à
Dignes les bains

Ikea

Voiture occasion

Jean luc godard

shopping, news, entertainment, sports, etc.

Partie 1

Constitution d'un index web

Architecture d'un moteur de recherche

Architecture d'un moteur de recherche

Objectifs

1. Qualité


- Objectif: Assurer la récupération des **documents les plus pertinents** en réponse à une requête utilisateur.
- Dans le but de: Répondre avec précision aux attentes et besoins des utilisateurs.

2. Rapidité

- Objectif: Traiter les requêtes des utilisateurs **le plus rapidement possible**.

Architecture d'un moteur de recherche

Des pages webs à l'index



Des pages webs à l'index

Text Acquisition

- Identifie et rend disponible les documents que l'on voudra montrer à l'utilisateur

1. Quels documents ?

- partir d'une collection de documents clés en main
- chercher ces documents via une tâche de **crawl** ou de **scrap**

2. Où les stocker?

Une base de données relationnelle peut être utilisée pour stocker les documents et leurs métadonnées.

Des pages webs à l'index

Text Acquisition

1. La notion de **crawler**

- Un crawler est conçu pour **suivre les liens** sur les pages web pour **découvrir** et télécharger de nouvelles pages
- Un bon crawler doit être capable de gérer efficacement l'énorme volume de nouvelles pages sur le Web, tout en veillant à ce que les pages qui ont pu être modifiées depuis la dernière visite d'un crawler restent "fraîches" pour le moteur de recherche

2. La notion de **scraper**

- Un scraper est un programme qui **extraît des données** spécifiques d'**une page web**. Contrairement au crawler, son objectif principal est de récupérer des informations ciblées sur une ou plusieurs pages web.

Des pages webs à l'index

Text Acquisition - Crawler

- Utilisation:
 - Le crawler est un des composants principaux d'un moteur de recherche
 - Archivage du web (Internet Archive, Common Crawl)
 - Exploration + analyses de données sur le web (ex: Attributor)
- Challenges:
 - **Scalabilité** —> Le web est très vaste et en constante évolution.
 - **Selection** des documents
 - Obligations de **politesse**
 - Qualité et **malveillance** des sites web

Des pages webs à l'index

Text Transformation

- Link extraction / analysis
- Information extraction (language, topic etc.)
- Parsing —> hierarchy extraction
- Stopping —> removing stop words
- Stemming / Lemmatization

Des pages webs à l'index

Création d'index

- **Entrée** : Utiliser la sortie de la transformation de texte pour créer des index.
- Objectif : Les index contiennent les informations nécessaires sur les documents pour permettre une recherche rapide et efficace.
- Contraintes :
 - **L'indexation** doit être **rapide** pour gérer un grand nombre de documents.
 - L'algorithme doit être optimisé en temps et en espace pour garantir une **utilisation efficace des ressources**.

Architecture d'un moteur de recherche

De la requête aux résultats finaux




Fig. 2.2. The query process

De la requête aux résultats finaux

Interaction utilisateur

1. Réception de la requête

- Le système reçoit en entrée :
 - **Texte** de la requête saisi par l'utilisateur
 - **Métadonnées** associées:
 - Langue de l'utilisateur.
 - Topics ou thématiques liés à la requête.
 - Informations contextuelles (heure, jour de la semaine, etc.).

2. Étapes de traitement

- Transformation de la requête pour qu'elle soit compatible avec l'index du système :
 - **Correction orthographique** (Spell checking).
 - **Enrichissement** ou augmentation de la requête :
 - Ajout de synonymes.
 - Expansion sémantique (ex. : “cinéma” → “films”, “projections”).
 - Prise en compte des métadonnées pour ajuster les résultats.

De la requête aux résultats finaux

Ranking

1. Input : Documents filtrés

- Le système reçoit les documents qui ont passé le filtre initial en fonction de la requête utilisateur.

2. Attribution d'un score aux documents

- Chaque document est analysé et évalué par rapport à la requête.
- Le score reflète la pertinence du document pour répondre à la demande de l'utilisateur.

3. Objectifs clés

- **Efficacité** : Traiter un grand nombre de requêtes rapidement (temps de réponse minimal).
- **Effectivité** :
 - Garantir un classement de haute qualité pour maximiser la pertinence des résultats.
 - Assurer que les documents les plus utiles apparaissent en priorité.

De la requête aux résultats finaux

Evaluation

- **Évaluation Offline**

- Définition : Tester le moteur de recherche sur des données préenregistrées.
- Objectif : Mesurer la qualité intrinsèque des algorithmes.
- Indicateurs clés :
 - Précision (Precision) / Rappel (Recall)
 - Mean Average Precision (MAP)
 - NDCG (Normalized Discounted Cumulative Gain)
- Avantage : Rapide et reproductible.
- Limite : Ne prend pas en compte le comportement réel des utilisateurs. Evaluation “online”

De la requête aux résultats finaux

Evaluation

- **Évaluation Online**
 - Définition : Tester le moteur directement sur des interactions réelles avec les utilisateurs.
 - Objectif : Évaluer la performance en situation réelle.
 - Méthodes clés :
 - A/B Testing : Comparer deux versions du moteur.
 - CTR (Click-Through Rate) : Taux de clics sur les résultats.
 - Dwell Time : Temps passé par l'utilisateur sur une page.
 - Avantage : Donne des insights basés sur l'expérience utilisateur.
 - Limite : Plus complexe et nécessite des données utilisateur.

Partie 1

Constitution d'un

index web

Crawler le web

Crawler le web

Décider de ce qu'il faut rechercher

- Les défis d'un crawler web
 - Un web immense et en constante évolution
 - **Croissance rapide** : Le web contient des milliards de pages et continue de s'étendre.
 - **Changements fréquents** :
 - Les pages web sont mises à jour régulièrement.
 - Les documents utiles aujourd'hui peuvent perdre de leur pertinence avec le temps.
 - Contraintes de **stockage**
 - Impossibilité de tout stocker
 - Priorisation des contenus
- Évaluation des crawlers
 - **Couverture** (Coverage) : Mesure la quantité de documents pertinents récupérés.
 - **Fraîcheur** (Freshness) : Indique à quel point les pages stockées sont actualisées.
- Règles de **politesse** pour les crawlers
 - Respect des serveurs web : Espacer les visites pour une URL donnée afin d'éviter une surcharge.
 - Suivre les directives du fichier **robots.txt** des sites web.


Crawler le web

Qu'est-ce qu'une page web ?

- Scheme
http | https | ftp | smtp
- Subdomain
indique le type de ressource
www | blog | audio etc.
- Domain
indique l'organisation
- TLD
indique le type d'organisation à laquelle le site web est enregistré.
pays: fr | co.uk | de
region: re
autre: com | org | net

Parts of a URL


URL : <https://www.example.co.uk:443/blog/article/search?docid=720&hl=en#dayone>



Crawler le web

Qu'est-ce qu'une page web ?


- Path
indique la localisation de la page dans son domaine
- Query
les paramètres d'un site web.
- Fragment
pour arriver directement à une certaine balise dans le document html



Crawler le web

Fonctionnement d'un crawler (Algorithme)

1. Entrée : Une liste initiale d'URLs (seed URLs).
2. Ajout à la file d'attente (Frontier)
 - Les URLs sont ajoutées à une file d'attente qui gère les requêtes :
 - La file d'attente peut être :
 - FIFO standard (ordre chronologique).
 - Prioritaire pour privilégier les pages importantes.
3. Récupération des pages web
4. Analyse des pages téléchargées
 - Identifier les balises de liens (<a>) contenant d'autres URLs.
 - Pour trouver de nouvelles URLs utiles à explorer
5. Ajout des nouvelles URLs
 - Si une URL n'a pas encore été visitée, elle est ajoutée à la frontière.
6. Cycle continu jusqu'à arrêt jusqu'à ce que :
 - La frontière soit vide (plus aucune URL à visiter).
 - Les ressources soient épuisées (disque plein, quotas atteints).



Crawler le web

Controler le crawler: robots.txt

- Les propriétaires de sites Web utilisent le fichier /robots.txt pour donner des instructions sur leur site aux crawlers
- Exemples de robots.txt
 - Site important
 - Site de niche
- Guidelines de google
- Informations sur le crawler de Qwant

Crawler le web

La notion de fraîcheur

1. Contraintes liées à la **fraîcheur**

- **Impossibilité de tout vérifier** : Il est irréaliste de contrôler constamment la fraîcheur de toutes les pages du web.

2. Priorisation des vérifications

- Pages **importantes** : Les pages avec un contenu critique ou très consulté sont vérifiées en priorité.
- Pages **fréquemment mises à jour** : Les pages qui changent souvent sont surveillées plus régulièrement.

3. Mesure de la fraîcheur

- Définition : La fraîcheur est la proportion des pages explorées qui contiennent des informations actuelles.
- Challenge : Si une page est mise à jour toutes les 2 secondes, maintenir sa fraîcheur devient extrêmement coûteux en ressources.

Crawler le web

La notion de fraîcheur

- Le cycle de vie d'une page :
 1. Lorsqu'une **page est crawlée**, elle est immédiatement considérée comme **fraîche**.
 2. Dès qu'un **changement** est détecté sur la page, celle-ci devient **périmée**.
 3. Une page a un **âge** de 0 jusqu'à sa première modification, puis cet âge **augmente** jusqu'à sa prochaine exploration.

Crawler le web

La notion de fraîcheur

- Jour 1 : Première exploration
 - Toutes les pages sont explorées pour la première fois, leur **âge est de 0 jours** (elles viennent d'être explorées).
 - Toutes les pages sont considérées comme fraîches car elles viennent d'être explorées et sont à jour.
 - **Fraîcheur du site = 100% (toutes les pages sont fraîches).**
- Jour 3 : Mise à jour partielle, seules les pages 1 et 2 sont redécouvertes
 - Pages 1 et 2 sont modifiées (nouveau contenu ajouté). -> Les pages 1 et 2 restent fraîches, car elles viennent d'être explorées.
 - Pages 3, 4 et 5 n'ont pas changé
 - Les pages 3, 4 et 5 sont maintenant considérées comme périmées car leur contenu n'a pas été mis à jour depuis la première exploration.
 - **L'âge des pages 3, 4 et 5 devient de 2 jours** (elles n'ont pas été explorées depuis 2 jours).
 - **Fraîcheur du site = 40% (2 pages fraîches sur 5).**
- Jour 5 : Nouvelle exploration
 - Toutes les pages sont explorées de nouveau.
 - Pages 1 et 2 sont explorées à nouveau, leur **âge est remis à 0 jours** car elles sont mises à jour.
 - Pages 3, 4 et 5 sont également explorées et mises à jour, leur âge est **également remis à 0 jours**.
 - Toutes les pages sont maintenant fraîches à nouveau, car elles ont été explorées récemment.
 - **Fraîcheur du site = 100% (toutes les pages sont fraîches).**

Crawler le web

Sitemaps

- Certains sites web exposent un sitemap aux crawler dans le robots.txt
- Exemple

⊗ Quel est l'intérêt de créer cette sitemap pour l'administrateur du site?

Crawler le web

Sitemaps

- Certains sites web exposent une **sitemap** aux crawler dans le robots.txt
- Exemple

⊗ Quel est l'intérêt de créer cette sitemap pour l'administrateur du site?

- Il indique aux moteurs de recherche des pages qu'ils ne trouveraient pas autrement.
- Cela permet de réduire le nombre de requêtes que le crawler envoie à un site web sans sacrifier la fraîcheur des pages.

Crawler le web

Stocker les documents

- La recherche de documents est couteuse en termes de CPU et de réseau.
- On va vouloir conserver une copie des documents déjà crawlés au lieu d'essayer de les récupérer à chaque fois qu'on lance un tour de crawl.
- En général on utilise une BDD relationnelle avec pour identifiant unique du document un hash de l'URL
- Exemple de BDD: Big Table

Crawler le web

Détecter les documents dupliqués

- Tâche plutôt simple
- On va souvent utiliser des techniques qui calculent les bytes des documents
- Baseline: **checksum technique**:
T r o p i c a l f i s h
54 72 6F 70 69 63 61 6C 20 66 69 73 68 result = 508
- **cyclic redundancy check**, une autre technique qui prend en compte la position des bytes.
- Attention: <http://monsite.com> != <https://monsite.com>

Crawler le web

Détecter les documents “presque” dupliqués (ou near duplicates)

- Tâche plus complexe
- Pour une url donnée, on va chercher à trouver tous ses “presque” duplicats dans la BDD.
- Pour cela, il faut représenter les documents
 - Soit en le hashant (e.g: sim-hash)
 - Soit avec des embeddings (vecteur dense de représentation d'un document)

Crawler le web

Focused crawler

- Dans certains cas, on va vouloir **prioriser certaines pages web** à crawler
- On considère alors
 1. l'importance d'une page ou d'un site par rapport aux autres
 2. la pertinence d'une page ou d'un site par rapport à l'objectif poursuivi par le crawl
 3. la dynamicité, ou la manière dont le contenu d'une page/d'un site a tendance à changer au fil du temps.

Partie 1

Constitution d'un index web

Extraction d'information à partir de documents

Extraire des informations des documents

- Avant d'ajouter nos documents dans un index, on va vouloir en extraire le plus d'informations possibles qui nous aideront à répondre de la manière la plus pertinente
 - Text Processing
 - Structure du document
 - Analyse des liens
 - Document embeddings

Différentes manières d'extraire des informations des sites web

Différentes manières d'extraire des informations

- HTML
 - Les sites de documentation (comme Python docs)
 - Beaucoup de sites gouvernementaux
- Javascript
 - LinkedIn / Airbnb / X etc.
- Flux RSS
 - News
- Dump réguliers
 - Reddit / Wikipedia
- API payantes
 - YouTube / Spotify / Wikipedia

Différents problèmes rencontrés

- HTML
 - Temps de réponse variables qui nécessitent des timeouts adaptés
 - Structure parfois peu sémantique ou mal structurée
- Javascript
 - Besoin d'un navigateur headless
 - Consommation importante de ressources (CPU/mémoire)

Différents problèmes rencontrés


- Flux RSS / Dumps réguliers
 - Limitations dans la fréquence de mise à jour des dumps
 - Parfois des restrictions d'accès aux dumps complets
 - Besoin de gérer de gros volumes de données
- API payantes
 - Coût
 - Versions d'API qui peuvent changer

Traitement du texte

Document Understanding

Text Processing | Vocabulaire

- Quelques mots apparaissent très souvent, beaucoup de mots n'apparaissent presque jamais.
- La taille du vocabulaire augmente avec le corpus
Mais il y a de moins en moins de mots nouveaux lorsque le corpus est déjà important
- Le vocabulaire est constitué de
 - mots **bien orthographiés** (dans différentes langues)
 - mots avec **fautes d'orthographe**
 - mots **inventés** (e.g: noms de produits, de sociétés, etc.)
 - adresses mails, suites de chiffres
 - etc.



Document Understanding

Text Processing | Représentations de mots

- **Word-level**

- Avantages : Maintient l'intégrité des mots, intuitif
- Inconvénients : Large vocabulaire, mauvaise gestion des mots rares/inconnus

- **Character-level**

- Avantages : Petit vocabulaire, peut gérer n'importe quel mot
- Inconvénients : Perd le sens au niveau du mot, séquences plus longues

- **N-grams**

- Avantages : Capture le contexte local
- Inconvénients : Explosion combinatoire des possibilités

- **“Le chat mange ses croquettes”**

- **Word-level**

- ["le", "chat", "mange", "ses", "croquettes"]

- **Character-level**

- ["l", "e", " ", "c", "h", "a", "t", " ", "m", "a", "n", "g", "e", " ", "s", "e", "s", " ", "c", "r", "o", "q", "u", "e", "t", "t", "e", "s"]

- **2-grams**

- ["le chat", "chat mange", "mange ses", "ses croquettes"]

Document Understanding

Text Processing | Représentations de mots

- **Tokens morphologiques**

- Avantages : Linguistiquement motivé
- Inconvénients : Nécessite des règles spécifiques à la langue

- **Tokens de sous-mots**

- Avantages : Équilibre entre taille du vocabulaire et préservation du sens
- Inconvénients : Peut créer des divisions contre-intuitives
- Les approches courantes incluent :
 - WordPiece (utilisé par BERT) : Divise les mots en unités de sous-mots communes
 - Byte-Pair Encoding (BPE, utilisé par GPT) : Fusionne itérativement les paires de caractères fréquentes

- **“Le chat mange ses croquettes”**

- Tokens morphologiques

- ["le", "chat", "mang", "#e", "ses", "croquet", "#ette", "#s"]

- Tokens de sous-mots

- Word-piece

- ["le", "chat", "mange", "ses", "cro", "##quettes"]

- BPE

- ["le", "ch", "at", "mange", "s", "es", "cro", "que", "ttes"]

Document Understanding

Text Processing | Des mots aux tokens

- Une **étape clé** dans le text processing, si la tokenization est mal réalisée, les étapes d'après vont en pâtir.
Elle est tellement importante qu'aujourd'hui on utilise souvent un **modèle entraîné** pour tokenizer.
- Considérations pratiques :
 - **La tokenisation doit être cohérente entre l'indexation et la recherche**
 - Il faut penser aux performances (temps de traitement)
 - La mémoire utilisée par l'index dépend directement des choix de tokenisation
 - Possibilité d'utiliser plusieurs types d'indexation en parallèle

Structure du document

Document Understanding

Document Structure | Supprimer le bruit contenu dans les documents

- Tâche: Boilerplate removal
- De nombreuses pages web contiennent du texte, des liens et des images qui ne sont pas directement liés au contenu principal de la page.
- Ces éléments supplémentaires sont pour la plupart du bruit et peuvent avoir un impact négatif sur le classement de la page.

WIKIPÉDIA

L'encyclopédie libre

Rechercher sur Wikipédia

Créer un compte

Sommaire [masquer]

Début

Dénominations

Évolution du langage

Description de HTML

Interopérabilité de HTML

Notes et références

Voir aussi

Hypertext Markup Language

ArticleDiscussion

LireModifierModifier le codeVoir l'historique

Le *HyperText Markup Language*, généralement abrégé **HTML** ou, dans sa dernière version, **HTML5**, est le **langage de balisage** conçu pour représenter les **pages web**.

Ce langage permet d'écrire de l'**hypertexte** (d'où son nom), de structurer **sémantiquement** une page web, de mettre en forme du contenu, de créer des formulaires de saisie ou encore d'inclure des **ressources multimédias** dont des **images**, des **vidéos**, et des **programmes informatiques**. L'HTML offre également la possibilité de créer des documents **interopérables** avec des équipements très variés et conformément aux exigences de l'**accessibilité du web**.

Il est souvent utilisé conjointement avec le **langage de programmation JavaScript** et des **feuilles de style en cascade** (CSS). HTML est inspiré du *Standard Generalized Markup Language* (SGML). Il s'agit d'un **format ouvert**.

Dénominations

[modifier | modifier le code]

L'**anglais** « *Hypertext Markup Language* » se traduit littéralement en « langage de balisage d'hypertexte »¹. On utilise généralement le **sigle** « HTML », parfois même en répétant le mot « langage » comme dans « langage HTML ». *Hypertext* est parfois écrit *HyperText* pour marquer le T du sigle HTML.

Le public non averti parle parfois de HTM au lieu de HTML, HTM étant l'**extension de nom de fichier** tronquée à trois lettres, une limitation que l'on trouve sur d'anciens **systèmes d'exploitation** de **Microsoft**.

Évolution du langage

[modifier | modifier le code]

Durant la première moitié des années 1990, avant l'apparition des **technologies Web** comme le langage **JavaScript** (JS), les **feuilles de style en cascade** (CSS) et le *Document Object Model* (DOM), l'évolution de HTML a dicté l'évolution du *World Wide Web*. Depuis la création de l'HTML 4 en 1997, l'évolution de HTML a fortement ralenti ; dix ans plus tard, HTML 4 reste utilisé dans les **pages web**. En 2008, la spécification du **HTML5** est à l'étude² et devient d'usage courant dans la seconde moitié des années 2010.

1989-1992 : Origine

[modifier | modifier le code]

HTML est une des trois inventions à la base du *World Wide Web*, avec le *Hypertext Transfer Protocol* (HTTP) et les **adresses web** (URL). HTML a été inventé pour permettre d'écrire des documents **hypertextuels** liant les différentes ressources d'**Internet** avec des **hyperliens**. Aujourd'hui, ces documents sont appelés « **page web** ». En août 1991, lorsque **Tim Berners-Lee** annonce publiquement le web sur **Usenet**, il ne cite que le langage **Standard Generalized Markup Language** (SGML), mais donne l'**URL** d'un document de suffixe `.html`.

Dans son livre *Weaving the web*³, **Tim Berners-Lee** décrit la décision de baser HTML sur SGML comme étant aussi « diplomatique » que technique : techniquement, il trouvait SGML trop complexe, mais il voulait attirer la communauté **hypertexte** qui considérait que SGML était le langage le plus prometteur pour standardiser le format des documents hypertexte. En outre, SGML était déjà utilisé par son employeur, l'**Organisation européenne pour la recherche nucléaire** (CERN). ;

Les premiers **éléments du langage HTML** comprennent :

- le titre du document,
- les **hyperliens**,

HTML

HyperText Markup Language



Caractéristiques

Extensions

.html, .htm

Type MIME

text/html

PUID

fmt/99

Développé par

World Wide Web Consortium & WHATWG

Version initiale

1993

Type de format

Langage de balisage

Basé sur

Standard Generalized Markup Language

Origine de

XHTML

Norme

ISO/IEC 15445

W3C HTML 4.01

W3C HTML5

ISO

15445

Spécification

Format ouvert

Site web

html.spec.whatwg.org/multipage

modifier - modifier le code - modifier Wikidata

56

Document Understanding

Les métadonnées

HTML

```
<meta name="author" content="Chris Mills" />
<meta
  name="description"
  content="The MDN Web Docs Learning Area aims to provide
complete beginners to the Web with all they need to know to get
started with developing websites and applications." />
```

HTML

```
<meta
  property="og:image"
  content="https://developer.mozilla.org/mdn-social-share.png" />
<meta
  property="og:description"
  content="The Mozilla Developer Network (MDN) provides
information about Open Web technologies including HTML, CSS, and APIs
for both websites
and HTML Apps." />
<meta property="og:title" content="Mozilla Developer Network" />
```

Document Understanding

Les métadonnées - Open Graph

```
HTML
<meta
  property="og:image"
  content="https://developer.mozilla.org/mdn-social-share.png" />
<meta
  property="og:description"
  content="The Mozilla Developer Network (MDN) provides
information about Open Web technologies including HTML, CSS, and APIs
for both websites
and HTML Apps." />
<meta property="og:title" content="Mozilla Developer Network" />
```

- Balises Open Graph obligatoires (si on utilise les metas og)
- og:title —> le titre de notre noeud
- og:type —> exemple: “video.movie”, en fonction du type, certaines autres propriétés doivent être spécifiées
- og:image —> l’url de l’image qui représente notre noeud
- og:url —> l’url de notre noeud, utilisée comme ID
- Pour aller plus loin

Document Understanding

Les métadonnées - JSON LD

- JSON - LD pour Linked Data
- Pour lier les documents web entre eux

```
{
  "@context": "https://json-ld.org/contexts/person.jsonld",
  "@id": "http://dbpedia.org/resource/John_Lennon",
  "name": "John Lennon",
  "born": "1940-10-09",
  "spouse": "http://dbpedia.org/resource/Cynthia_Lennon"
}
```

- Exemple avec Ensai.fr

Analyse des liens

Document Understanding

Analyse des liens

- Le crawler s'aide des liens entre les pages pour trouver de nouvelles pages à crawler
- Ces liens nous permettent
 - de créer un graphe du web
 - de comprendre les relations entre les pages
 - d'ordonner les pages en fonction de leur importance

Document Understanding

Analyse des liens

HTML



```
<p>
  I'm creating a link to
  <a href="https://www.mozilla.org/en-US/">the Mozilla homepage</a>.
</p>
```

HTML

</> Play 

```
<a href="https://developer.mozilla.org/en-US/">
  
</a>
```

Document Understanding

Analyse des liens

HTML

</> Play

```
<p>
  I'm creating a link to
  <a
    href="https://www.mozilla.org/en-US/"
    title="The best place to find more information about Mozilla's
        mission and how to contribute">
    the Mozilla homepage</a>.
</p>
```

- Le titre est seulement vu par l'utilisateur quand la souris passe dessus

HTML



```
<p>
  Want to write us a letter? Use our
  <a href="contacts.html#Mailing_address">mailing address</a>.
</p>
```

- Vers un fragment de la page

Document Processing

Analyse des liens | Le texte des ancres

- En général, un texte court qui décrit la page vers laquelle on va cliquer
Il peut avoir les memes caractéristiques qu'une requête web
- Extraire le texte des ancres nous permet ensuite de matcher ce texte avec la requête
- Peut être très utile pour les abréviations:
YouTube.com -> yt, ytb
- Mais doit etre nettoyé:
"Cliquez ici", "check here", "découvrir"

Document Processing

Analyse des liens | Le texte des ancres

HTML



```
<p><a href="https://www.mozilla.org/firefox/">Download Firefox</a></p>
```



HTML



```
<p>  
  <a href="https://www.mozilla.org/firefox/">Click here</a> to download  
  Firefox  
</p>
```



Document Processing

Analyse des liens | La popularité d'une page

- La majeure partie du web est composée de pages assez peu intéressantes, datées, ou de pages que l'on qualifie de spam
- On va donner un ou plusieurs score de qualité, de confiance aux urls
- Le plus connu: **Page Rank**

Document Processing

Analyse des liens | Page rank

- **Calcul du score de popularité d'une URL**
- **Principe** : Plus une URL A reçoit d'inlinks, plus elle est populaire.
- **Poids des liens** : Les liens provenant de pages populaires comptent plus. Ainsi, une page A ne sera pas favorisée si elle reçoit des liens de pages peu populaires ou de spam.
- **Objectif** : Calculer un score de popularité en prenant en compte la qualité des pages pointant vers A.
- Mots-clés :
 - Page = Document = Site = URL
 - Inlinks : Liens pointant vers une page
 - Outlinks : Liens d'une page vers d'autres pages

Document Processing

Analyse des liens | Page rank

- Algorithme “Random surfer model”
- **Principe** : Le modèle simule un utilisateur qui navigue au hasard sur le web.
- **Threshold** (ex. 0.15) : Contrôle la probabilité de choisir une page aléatoire, laissant une majorité des choix aux liens internes.
- **PageRank** : Le score de PageRank d'une page est la probabilité qu'un surfer arrive sur cette page.

```
func random_surfer_model(threshold)
  r <- random(0,1)
  if r < threshold
    choisis une page web aléatoire
  else
    clique sur un lien dans la page actuelle
  random_surfer_model(threshold)
```


Document Processing

Analyse des liens | Page rank

- L'algorithme tourne indéfiniment et explore plusieurs fois les sites, mais avec une probabilité plus élevée pour les sites populaires.

⚛ Problème sans le choix aléatoire ?

Document Processing

Analyse des liens | Page rank


- L'algorithme tourne indéfiniment et explore plusieurs fois les sites, mais avec une probabilité plus élevée pour les sites populaires.
- Problème sans le choix aléatoire ?
 - L'algorithme pourrait se retrouver bloqué sur :
 - Des pages sans liens
 - Des pages dont les liens sont cassés
 - Des pages dans des boucles infinies

Document Processing

Analyse des liens | Page rank


- Au départ toutes les pages ont le même page rank

⚛️ Quelle serait la page la plus populaire dans cet exemple?



Document Processing

Analyse des liens | Page rank



	Iteration 0	Iteration 1	Iteration 2	Final Rank
P_1	$1/5$	$1/20$	$1/40$	5
P_2	$1/5$	$5/20$	$3/40$	4
P_3	$1/5$	$1/10$	$5/40$	3
P_4	$1/5$	$5/20$	$15/40$	2
P_5	$1/5$	$7/20$	$16/40$	1

Document Processing

Analyse des liens | Page rank

$$PR(u) = \frac{\lambda}{N} + (1 - \lambda) \cdot \sum_{v \in B_u} \frac{PR(v)}{L_v}$$

- N -> le nombre de documents
- λ -> probabilité de choisir une page random
 $1 - \lambda$ -> probabilité de cliquer sur un lien
- B_u -> inlinks de l'url u
- L_v -> # outlinks depuis l'url v

Document Embeddings

Document Embeddings

Dense representations | BERT-like embeddings

- Embeddings: représentation vectorielle d'une string (plus ou moins longue)
- BERT-like embeddings: représentation contextualisée au niveau du **word-piece**
Exemple:
 - Danone est mon yaourt préféré
 - Je déteste DanoneLe vecteur de Danone sera différente
- **Problèmes en recherche d'information:**
 - Ce sont des representation assez **longues à générer**
Comme elles dependent du contexte, on ne peut pas simplement avoir une hashmap de token -> vecteur
 - Ces embeddings ont une contrainte de taille de la string en input, **un document web est souvent bien plus long**
On choisit alors
 - soit de représenter le début du document
 - soit de diviser le document en chunks de max 512 wp et de multiplier les vecteurs résultants
 - Soit de partir d'un summary du document

Document Embeddings

Dense representations | ColBERT

- Similarité entre la requête et le document
- Un même modèle qui encode la requête et le document séparément et donne un score de similarité entre un document et une requête
- On va encoder le document au moment de l'indexation
On n'aura plus qu'à encoder la requête

Partie 2

Traitement de la requête et ordonnancement des résultats

Rappels

Traitement de la requête et ordonnancement des résultats

- A ce stade, on a:
 - Une base de données avec des milliards de documents
 - Ces documents ont été process pour en extraire plusieurs informations:
 - Textuelles: title, content, metatags, headers etc.
 - Scores: popularité (ex: page rank), confiance, spam etc.
 - Induites: langue, topic etc.

Traitement de la requête et ordonnancement des résultats

